Práctica curso 26-27

Métodos Clásicos para Predicción

Grado en Ciencia de Datos e Inteligencia Artificial

Esta práctica consiste en dos problemas, uno en el que aplicarás técnicas de reducción de dimensionalidad sobre trazas de red y otro en el que aplicarás modelos de regresión y análisis de series temporales sobre datos de consumo eléctrico. Se realiza en parejas, que deberán estar dadas de alta en Moodle.

DATOS

Descarga de Moodle los cinco ficheros y colócalos en una carpeta llamada datos/ junto a tus notebooks.

```
practica/
  datos/
    trazas_red_entrenamiento.csv
    trazas_red_test.csv
    consumo_campus.csv
    bloques.csv
    meteorologia.csv
  ataques_red.ipynb
  consumo_campus.ipynb
```

PROBLEMA 1: PROTEGIENDO LA ETSISI DE ATAQUES DE RED

Son trazas de tráfico de red capturadas en un laboratorio de ciberseguridad, en el que se combinó actividad legítima de fondo con ataques lanzados en condiciones controladas. Todo el tráfico se capturó en bruto y después se procesó con herramientas de análisis de red, que resumen cada conversación en una fila de características. Cada traza no es un paquete**, sino el resumen estadístico** de una conversación completa entre dos máquinas. Por eso las características son totales, medias y tiempos, y no contenidos. Cada traza lleva en la columna etiqueta el tipo de tráfico al que corresponde: normal o una de nueve familias de ataque.

Las 43 columnas son 42 características (39 numéricas y 3 categóricas) más la etiqueta. No hay ninguna columna identificadora ni ningún índice: todas las columnas, salvo la etiqueta, son utilizables. El diccionario completo de las 42 características está en el apéndice B.

Los tipos de tráfico

Este es el reparto por etiqueta. Fíjate en que no es el mismo en los dos ficheros: no es un descuido, es deliberado, y tiene consecuencias que se evalúan en el apartado 1.1.

Etiqueta	Qué es
Normal	Tráfico legítimo de fondo
Criptoanalisis	Ataque contra cifradores por bloques que funciona con independencia de su configuración concreta
Explotacion	Aprovechamiento de una vulnerabilidad conocida del sistema o de la aplicación
Fuzzing	Envío masivo de entradas generadas al azar para provocar un fallo o una caída
Denegacion	Agotar los recursos del objetivo hasta dejarlo sin capacidad de responder
Reconocimiento	Barridos y recolección de información previa sobre el objetivo
Sondeo	Exploración de puertos, correo no deseado y penetración de aplicaciones web
Puerta_trasera	Acceso persistente al sistema evitando los mecanismos de autenticación
Inyeccion_shell	Carga útil que, al ejecutarse, abre una shell en la máquina atacada
Gusano	Código que se replica a sí mismo y se propaga por la red sin intervención

Las 42 características no son una lista plana: provienen de etapas distintas del procesado del tráfico y se pueden agrupar de forma natural en varios grupos. Pensar en grupos es lo que te permitirá después interpretar las componentes principales.

El servicio de informática quiere un sistema que, a partir de los metadatos de cada flujo de red, distinga el tráfico legítimo de los distintos tipos de ataque.

1.1 Estudio cualitativo (7 puntos)

- Describe qué mide cada característica y agrúpalas según la etapa del procesado del tráfico de la que provienen.
- Describe las nueve familias de ataque y agrúpalas en superfamilias. La agrupación debe responder a un criterio explícito y defendible (por ejemplo, la fase de la cadena de ataque), no a la conveniencia numérica.
- Compara el reparto de etiquetas entre entrenamiento y test. Si no coincide, explica qué implica eso para la evaluación.

1.2 Estudio cuantitativo (7 puntos)

- Estudia escalas, asimetría y proporción de ceros de las características numéricas. Justifica a partir de ahí qué transformación vas a aplicar antes del PCA y por qué es imprescindible.
- Calcula la matriz de correlación e identifica los grupos de características redundantes.
- Mide la asociación de las tres características categóricas con la etiqueta, usando una medida adecuada para variables nominales.

1.3 Truncated SVD sobre las características categóricas (8 puntos)

- Codifica one-hot protocolo, servicio y estado_conexion, y aplica Truncated SVD sobre la matriz dispersa resultante. Justifica, con lo visto en el tema 3.2, si procede usar PCA.
- Trata la cola de protocolos poco frecuentes antes de ajustar, y explica por qué no hacerlo distorsiona los ejes.
- Representa el mapa de modalidades y la proyección de las trazas. Interpreta las primeras componentes en términos de red, no de álgebra: qué distingue un extremo del eje del otro.
- Presta atención a la primera componente antes de interpretarla: Truncated SVD no centra la matriz, y eso tiene una consecuencia muy concreta sobre lo que esa componente representa. Explícala.

1.4 PCA y técnicas no lineales para visualizar (8 puntos)

- Haz uso del análisis de componentes principales sobre las características numéricas. Presenta la curva de varianza explicada acumulada, el número de componentes necesarias para superar el umbral habitual del 90 % y la lectura de las cargas de las dos primeras.
- Representa las familias de ataque en el plano de las dos primeras componentes principales.
- Aplica además ISOMAP y t-SNE sobre los mismos datos y compara cuál consigue separar mejor los tipos de ataque entre sí. Comenta qué conserva cada una: la geometría global o la vecindad local, y qué implica eso al leer el gráfico.
- Indica qué familias se solapan.

1.5 Reducción de dimensionalidad para clasificar (12 puntos)

Para este apartado ten en cuenta lo siguiente:

- Debes entrenar sobre el fichero de entrenamiento y evaluar sobre el de test.
- La selección de modelo se hace por validación cruzada estratificada dentro del entrenamiento
- Todo el preprocesado (escalado, transformaciones, PCA) debe ir dentro de un Pipeline, de modo que se reajuste cada vez.
- Como métrica principal usa F1 macro. Reporta además balanced accuracy y la matriz de confusión.
- Utiliza un modelo de clasificación simple como baseline y compara todos los modelos con él

Con ese protocolo:

- Compara al menos cuatro clasificadores de scikit-learn de familias distintas.
- Compara cada uno con y sin reducción de dimensionalidad, variando el número de componentes. Responde con datos a la pregunta: ¿permite la reducción de dimensionalidad lograr una mejor clasificación de las trazas? Argumenta tu respuesta.
- Cuantifica la diferencia entre el rendimiento en validación cruzada y el rendimiento en el test, y explica a qué se debe.
- Analiza la matriz de confusión: dónde se concentran los errores y qué significa eso para un centro de operaciones de seguridad.

◦ Como experimento de control, muestra qué resultado obtendrías uniendo los dos ficheros y partiéndolos al azar, y cuantifica la sobrestimación.

1.6 Ataques no vistos (5 puntos)

• Elimina por completo una familia de ataque del entrenamiento, entrena de nuevo y observa qué hace el modelo con esa familia en el test. Repítelo con al menos tres familias distintas.

• Distingue dos cosas: qué proporción se sigue detectando como ataque, aunque sea de otra familia, y qué proporción escapa como tráfico normal.

• Comenta por qué el coste de esos dos errores no es el mismo y qué métrica llevarías a un comité de operaciones.

PROBLEMA 2: MEJORANDO LA EFICIENCIA ENERGÉTICA EN LA UPM

El dataset consiste en datos de consumo eléctrico horario, contador a contador, de edificios universitarios durante 2016 y 2017, con meteorología horaria asociada. Se han seleccionado tres sedes, que aquí se denominan Campus Norte, Campus Sur y Rectorado. Se trata de datos ficticios y no reales de la UPM.

FICHEROS Y ESTRUCTURA

consumo_campus.csv — 17.544 filas (una por hora, del 1 de enero de 2016 al 31 de diciembre de 2017) y 282 columnas:

Columna	Contenido
fecha_hora	Marca temporal horaria, en hora local del campus
NOR_001 … REC_052	Una columna por contador, con el consumo de esa hora en kWh. El prefijo indica el campus: NOR Campus Norte, SUR Campus Sur, REC Rectorado. Un valor ausente significa que el contador no reportó esa hora

bloques.csv — 281 filas, una por bloque:

Columna	Contenido
bloque	Código del bloque, coincide con el nombre de columna en consumo_campus.csv
campus	Campus Norte, Campus Sur o Rectorado
uso	Uso principal: Docente, Oficinas, Residencial, Servicios publicos, Actos publicos…
superficie_m2	Superficie en metros cuadrados. Entre 36 y 75.207, mediana 6.150
anio_construccion	Año de construcción. Disponible solo en 226 de los 281 bloques
plantas	Número de plantas, con bastantes ausencias
ocupacion	Ocupación declarada. Está vacía en los 281 bloques: no se puede usar

meteorologia.csv — 52.601 filas, una por hora y campus:

Columna	Contenido
fecha_hora, campus	Hora y campus al que corresponde la medida
temperatura	Temperatura del aire en grados Celsius. Sin ausencias
punto_rocio	Temperatura de rocío en grados Celsius. Sin ausencias

Columna	Contenido
nubosidad	Nubosidad en octavos. Ausente en más de la mitad de las horas
precipitacion	Precipitación acumulada en una hora, en milímetros. Ausente en un tercio de las horas
viento	Velocidad del viento en metros por segundo

LOS TRES CAMPUS

Campus	Bloques	Temperatura (mín/media/máx)	Perfil de usos
Campus Norte	92	0,6 / 15,1 / 38,3 °C	Muy docente
Campus Sur	137	2,2 / 25,1 / 48,3 °C	Docente y residencial
Rectorado	52	-4,1 / 11,8 / 33,9 °C	Alto peso de oficinas

El servicio de mantenimiento quiere anticipar el consumo eléctrico del próximo semestre para negociar la compra de energía y planificar paradas. La pregunta que hay que responder no es qué modelo tiene el error más bajo, sino si algún modelo bate a la regla más simple posible. Se pide lo siguiente.

2.1 ESTUDIO DEL DATASET (5 PUNTOS)

- Realiza un estudio detallado, cualitativo y cuantitativo
- Analiza la calidad del dato: huecos, ceros y valores imposibles. ¿Un cero sostenido es consumo nulo?
- Construye la serie diaria agregada de cada campus documentando las decisiones de agregación.

2.2 VISUALIZACIÓN (7 PUNTOS)

- Realiza visualizaciones que permitan entender el consumo medio por bloque y campus en función de diferentes medidas de tiempo: horas, días, semanas y meses.
- Incluye una representación que muestre las dos estacionalidades a la vez.
- Estudia la relación entre consumo y temperatura. Si no es lineal, di qué forma tiene y qué transformación la linealiza.

2.3 EVENTOS Y CALENDARIO (7 PUNTOS)

- Describe los momentos temporales en los que se han producido eventos con un efecto importante sobre el consumo. Detecta tanto días atípicos como cambios de nivel, con un criterio robusto y explícito, no a ojo.
- Atención: si no separas días laborables de fines de semana, lo único que detectarás es la estacionalidad semanal que ya conocías.

- Los campus están anonimizados. A partir de los días atípicos, argumenta qué calendario laboral sigue cada uno. No tienen por qué ser el mismo.
- La detección se hace únicamente sobre el periodo de entrenamiento. Usar el periodo de test para construir variables es fuga de información.

2.4 Protocolo de evaluación (8 puntos)

Para este apartado ten en cuenta lo siguiente

- Entrenamiento: del 1 de enero de 2016 al 30 de junio de 2017. Test: del 1 de julio al 31 de diciembre de 2017, los seis meses posteriores.
- Reporta MAE, RMSE y MAPE, las métricas de evaluación para regresión del tema 2.2.
- La decisión se toma con el **cociente frente al ingenuo**: el MAE del modelo dividido por el MAE del ingenuo estacional semanal sobre la misma ventana. Vale 1 para el propio ingenuo, menos de 1 si el modelo lo mejora y más de 1 si lo empeora. A diferencia del MAE y del RMSE, es adimensional y por tanto comparable entre campus y entre bloques de tamaños muy distintos. En la literatura de series temporales esta idea se conoce como MASE.
- Baselines obligatorios: el enfoque de repetir el último valor del tema 4.2.1, el ingenuo estacional semanal (reciclar la última semana observada) y el ingenuo estacional anual (mismo día del año anterior).

2.5 Enfoques simples y regresión con variables exógenas (9 puntos)

- Aplica primero los dos enfoques simples del tema 4.2: el suavizado exponencial y el de ventana de anchura W con un regresor estándar de scikit-learn. Al horizonte que se pide hay que aplicarlos de forma recursiva; comenta el resultado a la luz de lo que se dice en clase sobre el alcance temporal de estos métodos.
- Ajusta después una regresión lineal múltiple del consumo diario sobre día de la semana, grados-día de calefacción y refrigeración, estacionalidad anual y el calendario de festivos que hayas identificado en 2.3.
- Si la relación con la temperatura no queda bien recogida, puedes probar las alternativas del tema 2: regresión polinómica sobre la temperatura, o regularización si el número de regresores crece. Justifica la elección con las métricas.
- Haz una diagnosis completa de los residuos: gráficos de residuos, normalidad y autocorrelación.

2.6 Análisis de series temporales (9 puntos)

- Descompón la serie en tendencia, componente estacional y residuo mediante medias móviles, y mide la fuerza de cada componente.
- Estudia la estacionariedad débil de la serie: comprueba si la media y la desviación típica se mantienen estables a lo largo del tiempo, y analiza la función de autocorrelación. Si quieres, apóyate además en un contraste formal.
- Aplica la diferenciación necesaria para estacionalizar la serie, regular y estacional, y justifica cuánta hace falta. Si las distintas herramientas sugieren cosas distintas, explica la discrepancia en lugar de elegir la que te convenga; y explica también qué ocurre si se sobrediferencia.

- Identifica los órdenes del modelo a partir de la función de autocorrelación y de la autocorrelación parcial, y contrasta esa lectura probando varios órdenes y comparándolos con un criterio objetivo.
- Estima el modelo mediante máxima verosimilitud, haz la diagnosis de los residuos del modelo ajustado y predice el periodo de test.
- Compara un ARIMA sin variables exógenas frente a un SARIMAX con ellas, y ambos frente a la regresión del apartado anterior. Explica el resultado en términos del horizonte de predicción.

2.7 Análisis por bloque (8 puntos)

- Haz un análisis individualizado por cada uno de los bloques. Extrae la serie temporal, agrupa los datos por día y automatiza el pipeline; presenta una tabla comparativa y analiza en profundidad solo tres bloques, elegidos y justificados a partir de esa tabla.
- Cierra con un diagnóstico: describe los problemas, si los hay, para conseguir cifras de acierto más altas, y qué información adicional haría falta.

ENTREGA FINAL

Se debe entregar un fichero comprimido .zip con el siguiente nombre:

```
APELLIDO1_APELLIDO2_GRUPO_XX.zip
```

donde APELLIDO1 y APELLIDO2 sean los primeros apellidos de los dos integrantes de la práctica, y XX el número asignado al grupo de prácticas en Moodle. Este fichero contendrá:

Fichero	Contenido
Memoria.pdf	Una memoria detallada de todo el trabajo realizado, sin código. Máximo 30 páginas incluyendo figuras, portada y anexos
ataques_red.ipynb	Un notebook con todos los pasos realizados en el Problema 1, con las salidas ejecutadas
consumo_campus.ipynb	Un notebook con todos los pasos realizados en el Problema 2, con las salidas ejecutadas
requirements.txt	Versiones de las bibliotecas utilizadas

Importante

Todos los notebooks y código deberán estar correctamente documentos utilizando celdas de markdown, explicando todos los pasos realizados, los resultados obtenidos y toda decisión tomada. Una explicación escasa o no suficientemente detallada conllevará el suspenso en la práctica.